Cas Kaggle
Mushrooms classification

Albert Roca i Llevadot

Github :
https://github.com/AlbertRoca29/Mushrooms

Un dataset amb variables categoriques

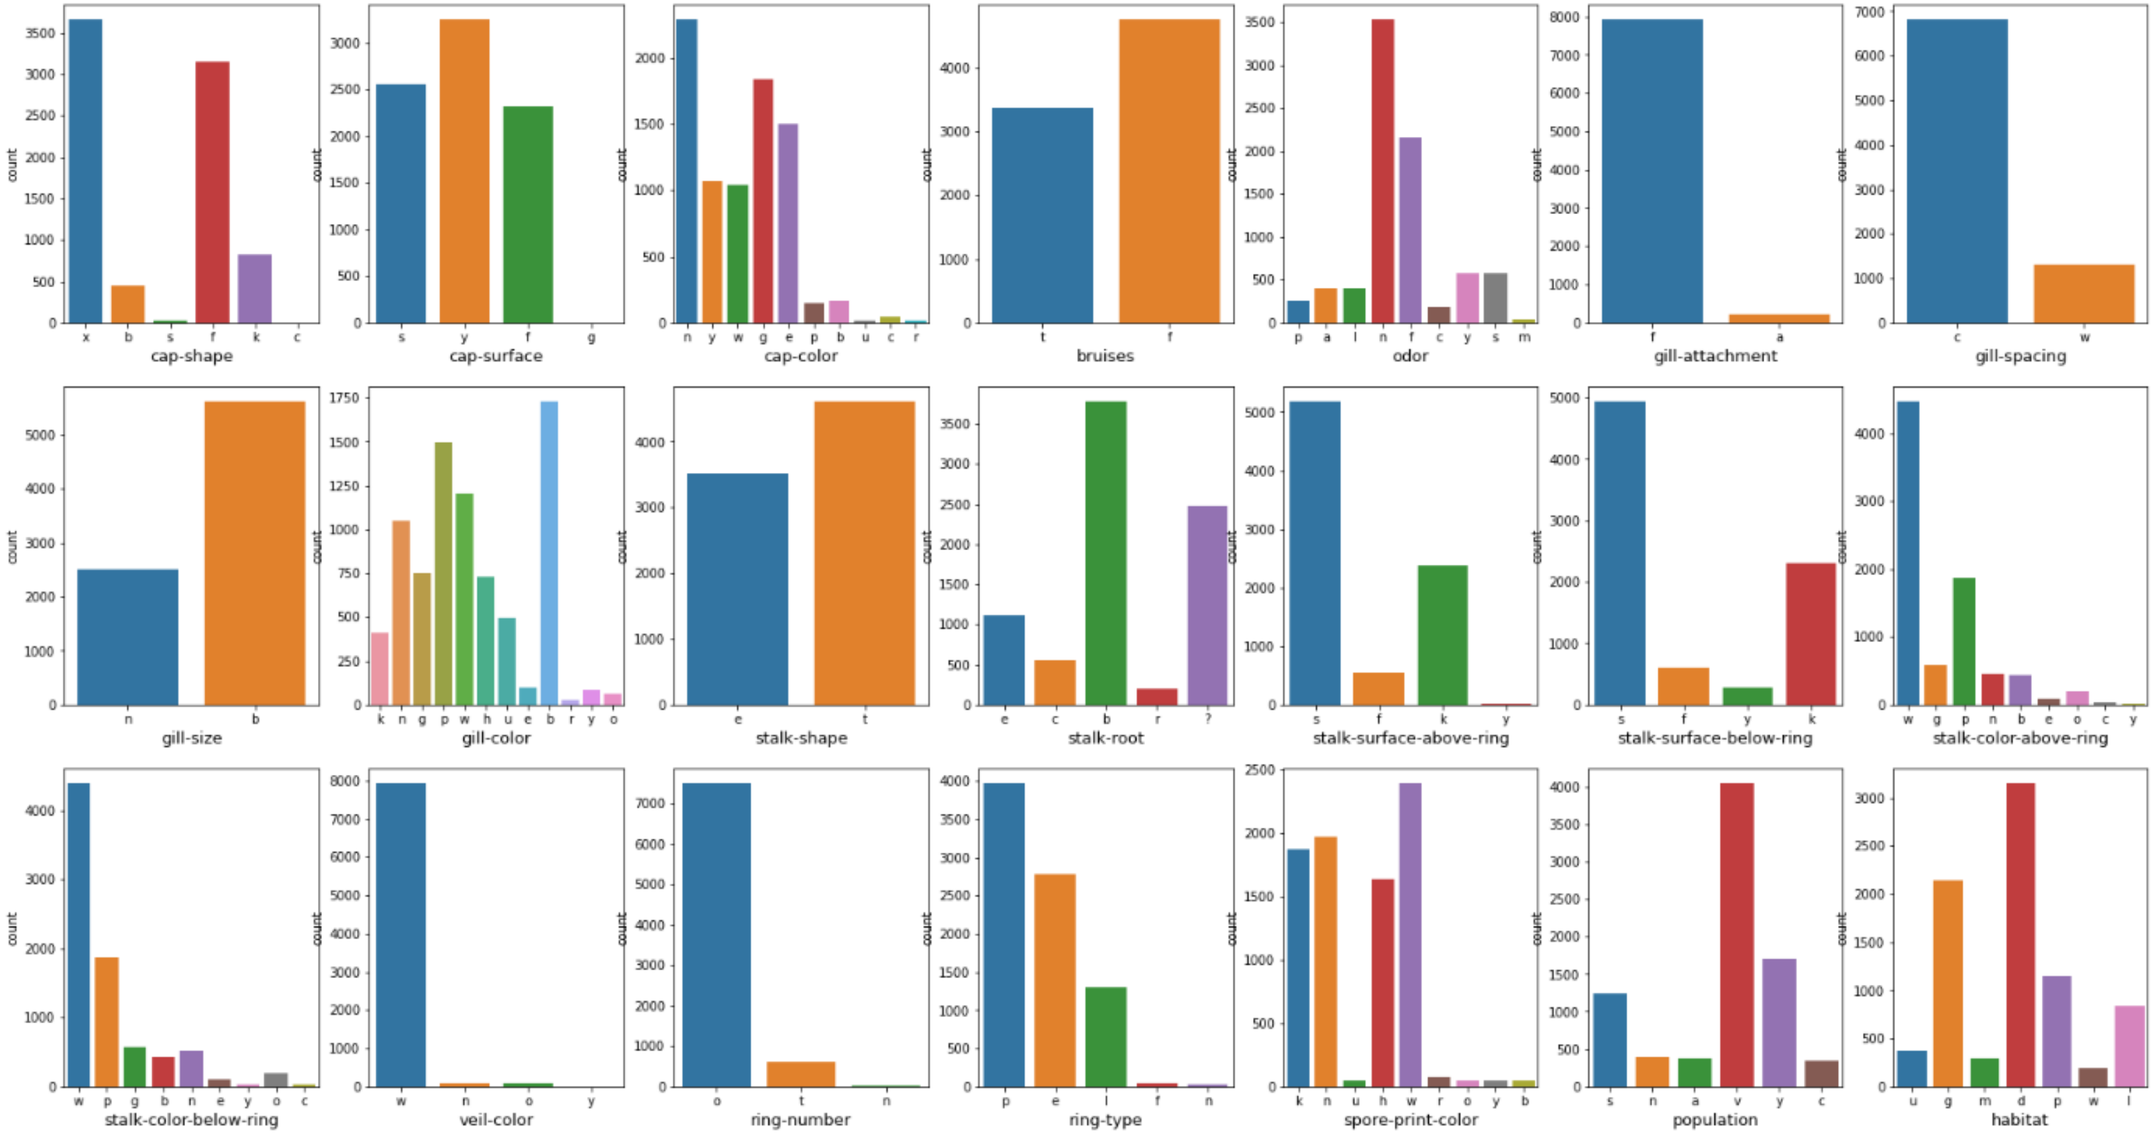

Objectiu:

Classificar els bolets entre verinosos i comestibles

Un dataset amb variables categoriques

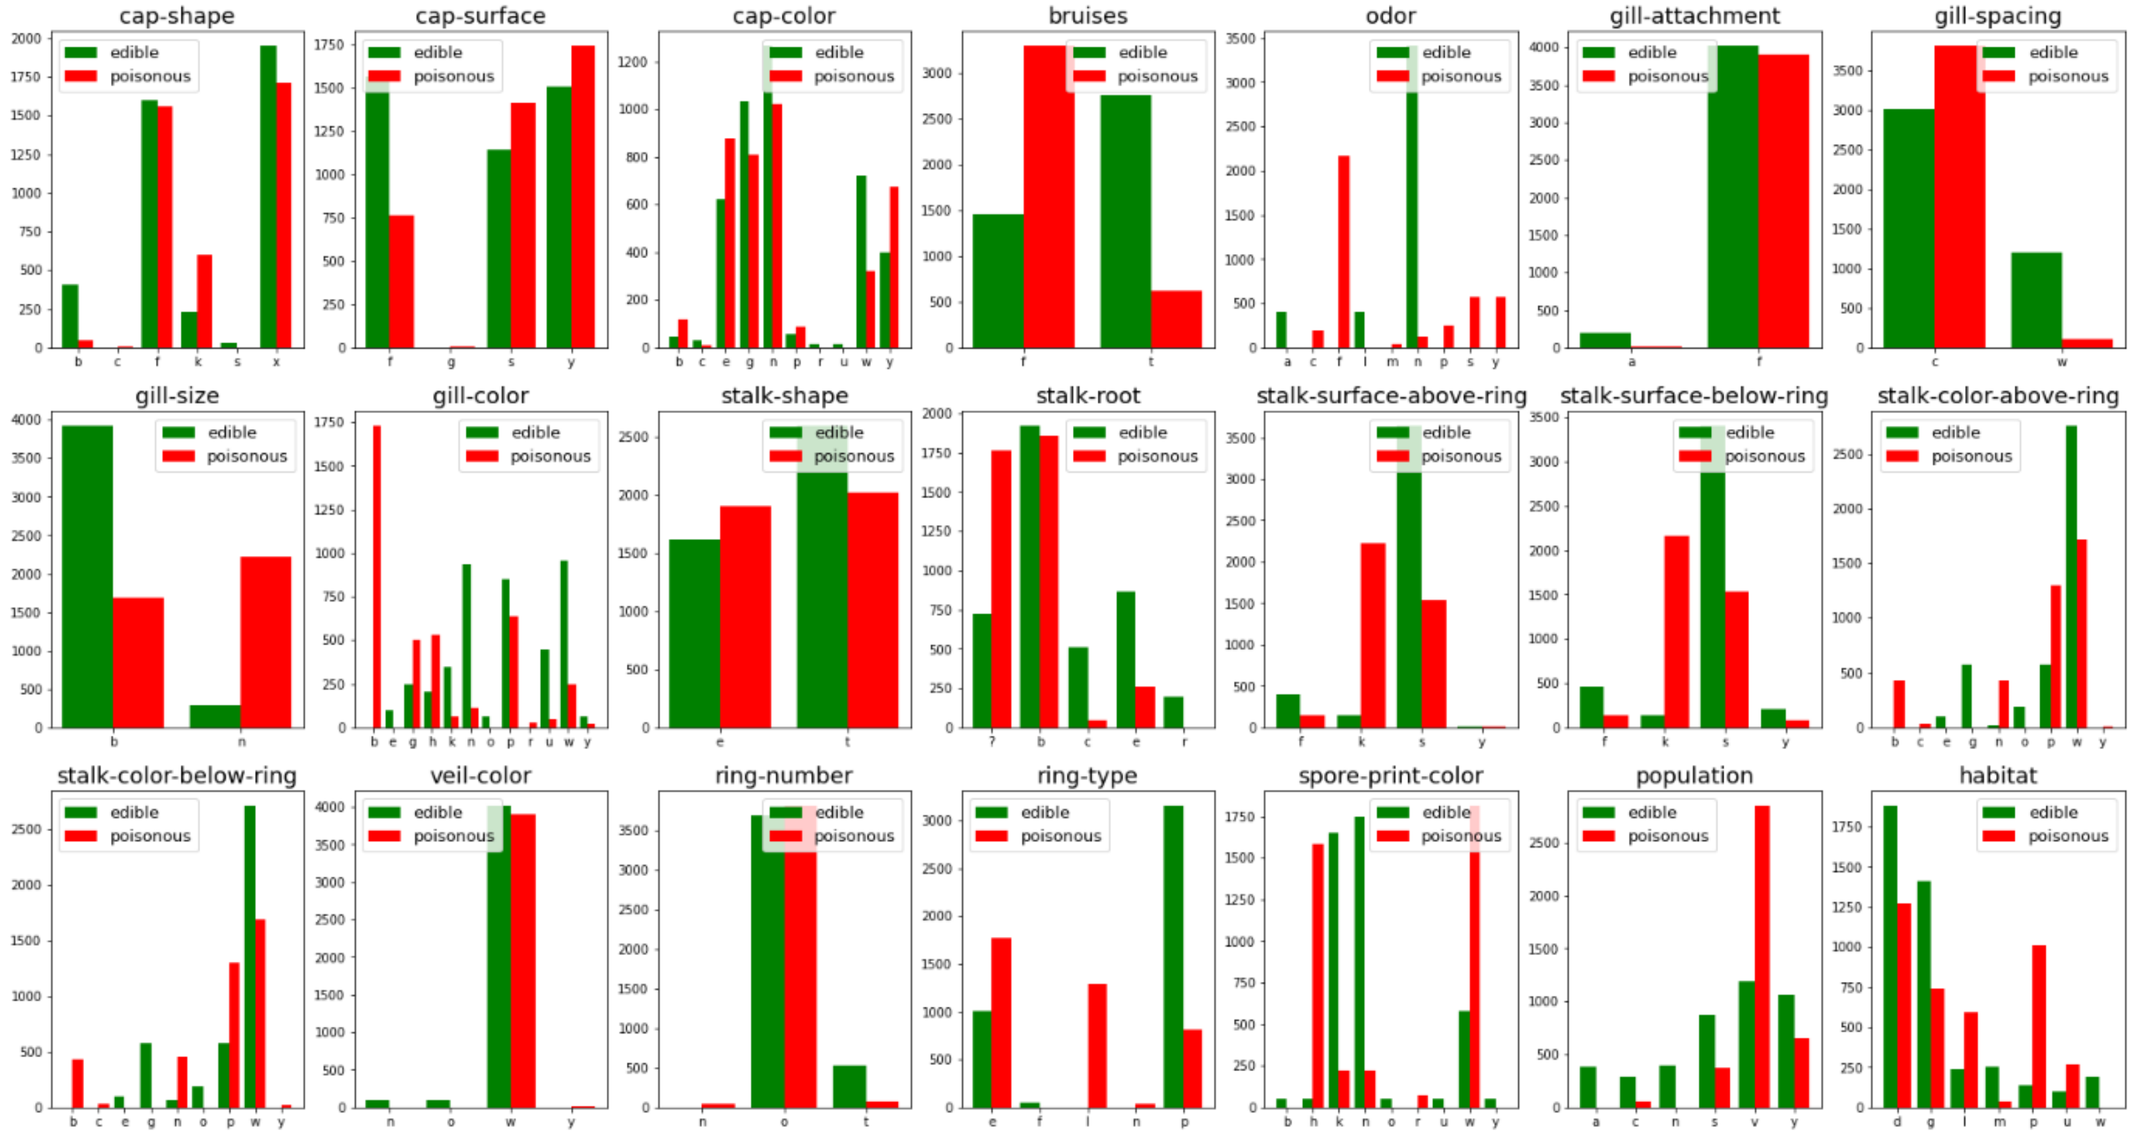

Un dataset amb variables categoriques

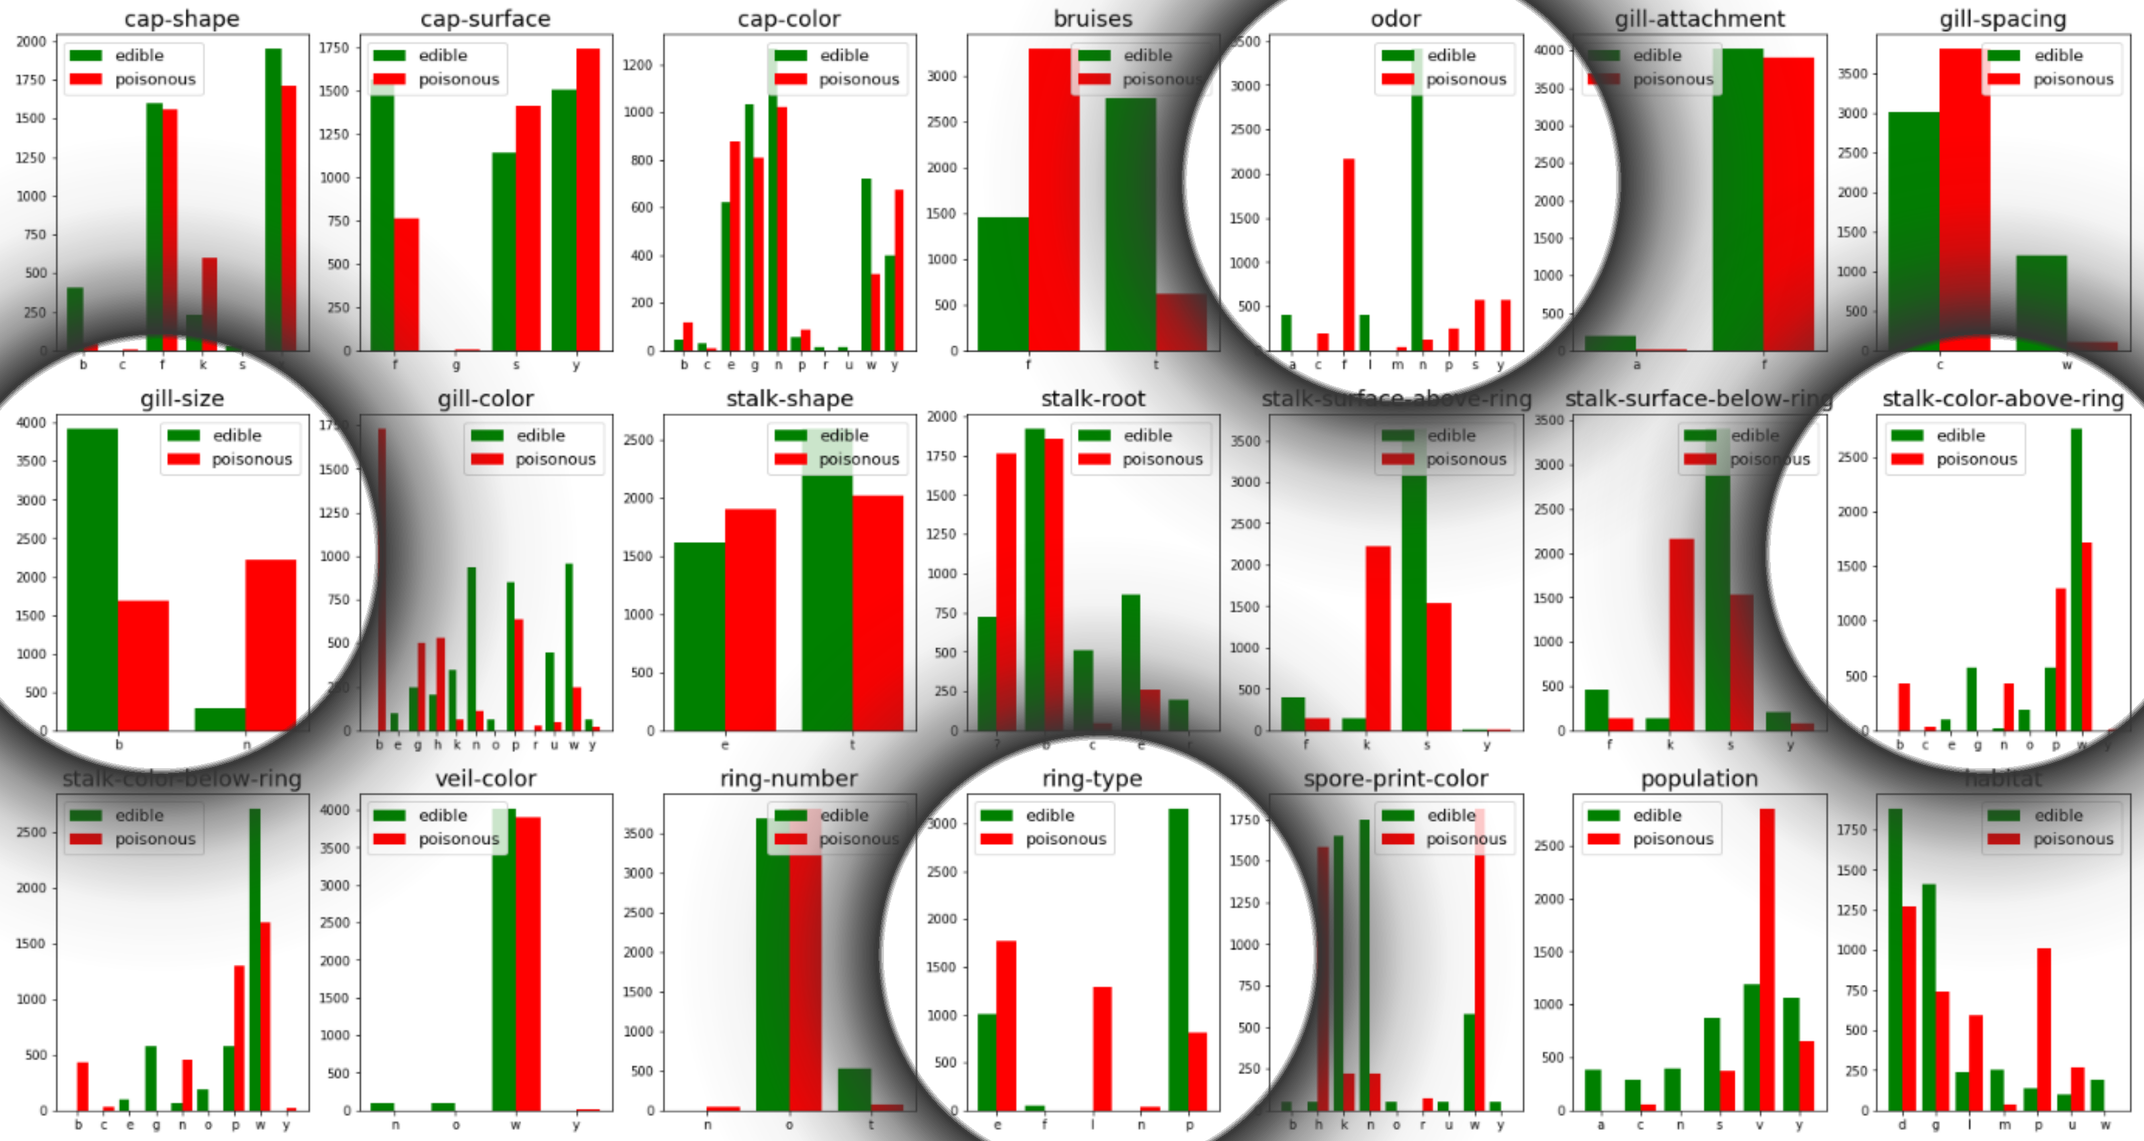

Variables categoriques

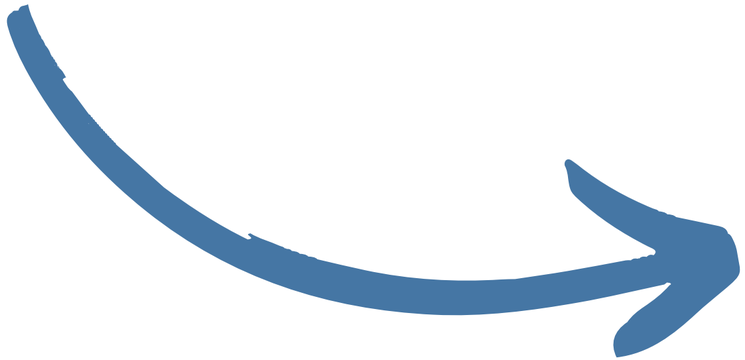

Dummies

21
variables

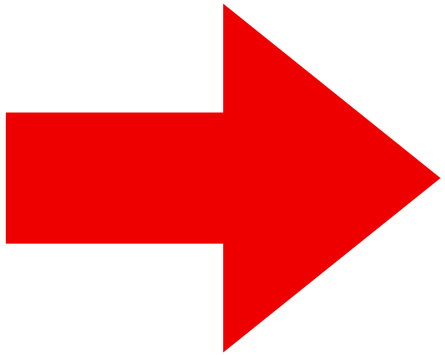

116
variables

Primera classificació

ACCURACY

100%

Amb tots els models escollits

Malgrat l'overfitting, l'accuracy és impecable.

Veig que és una variable molt fàcil de predir amb les dades que tinc

Aleshores, que faig ?

Decideixo basar el treball en :

1. Quins atributs van millor i com augmenta l'acuracy amb cada un d'ells
2. Reduir la dimensió amb t-SNE i PCA.
3. Visualitzar els resultat i veure fins a on puc arribar mantenint aquesta alta accuracy.

1 Quins atributs van millor i com augmenta l'acuracy amb cada un d'ells

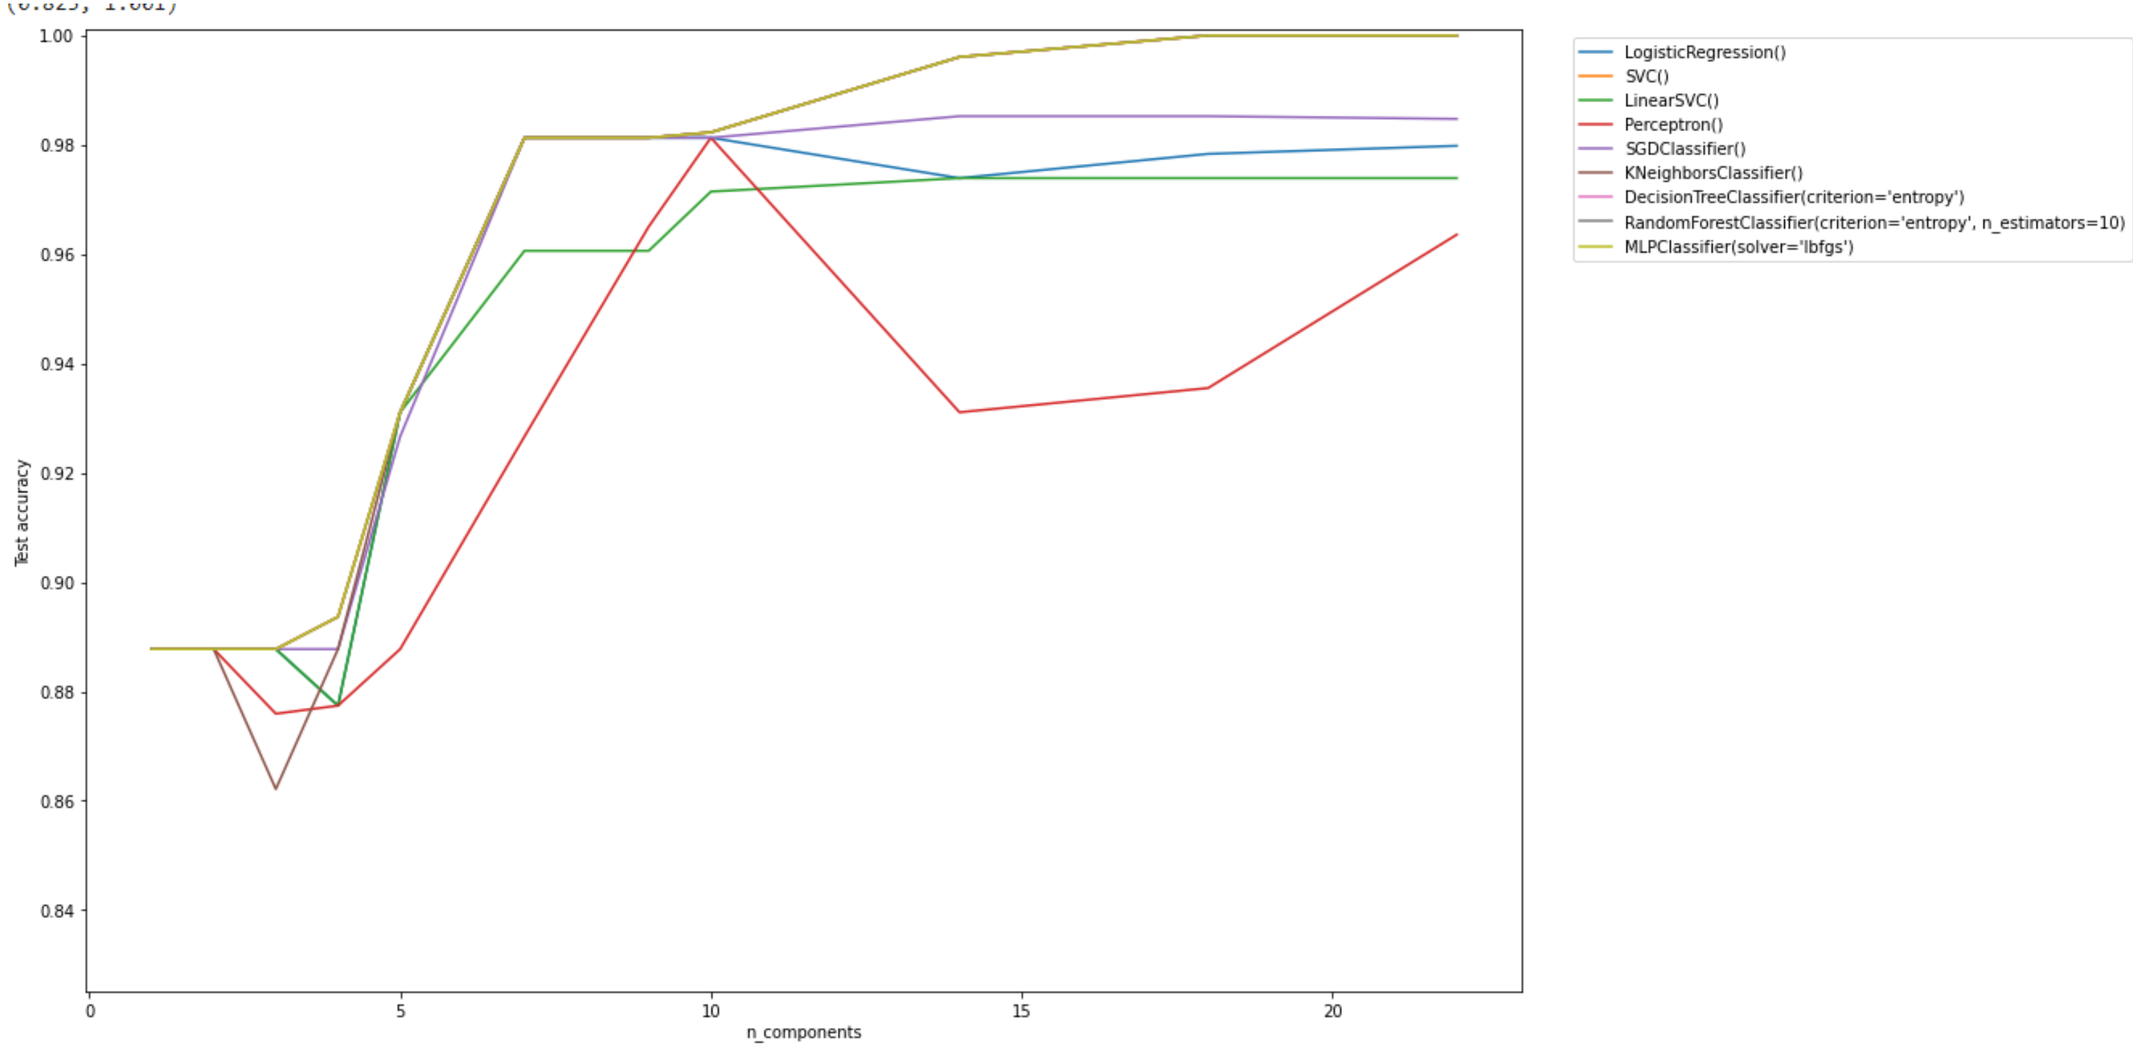

1

Quins atributs van millor i com augmenta l'acuracy amb cada un d'ells

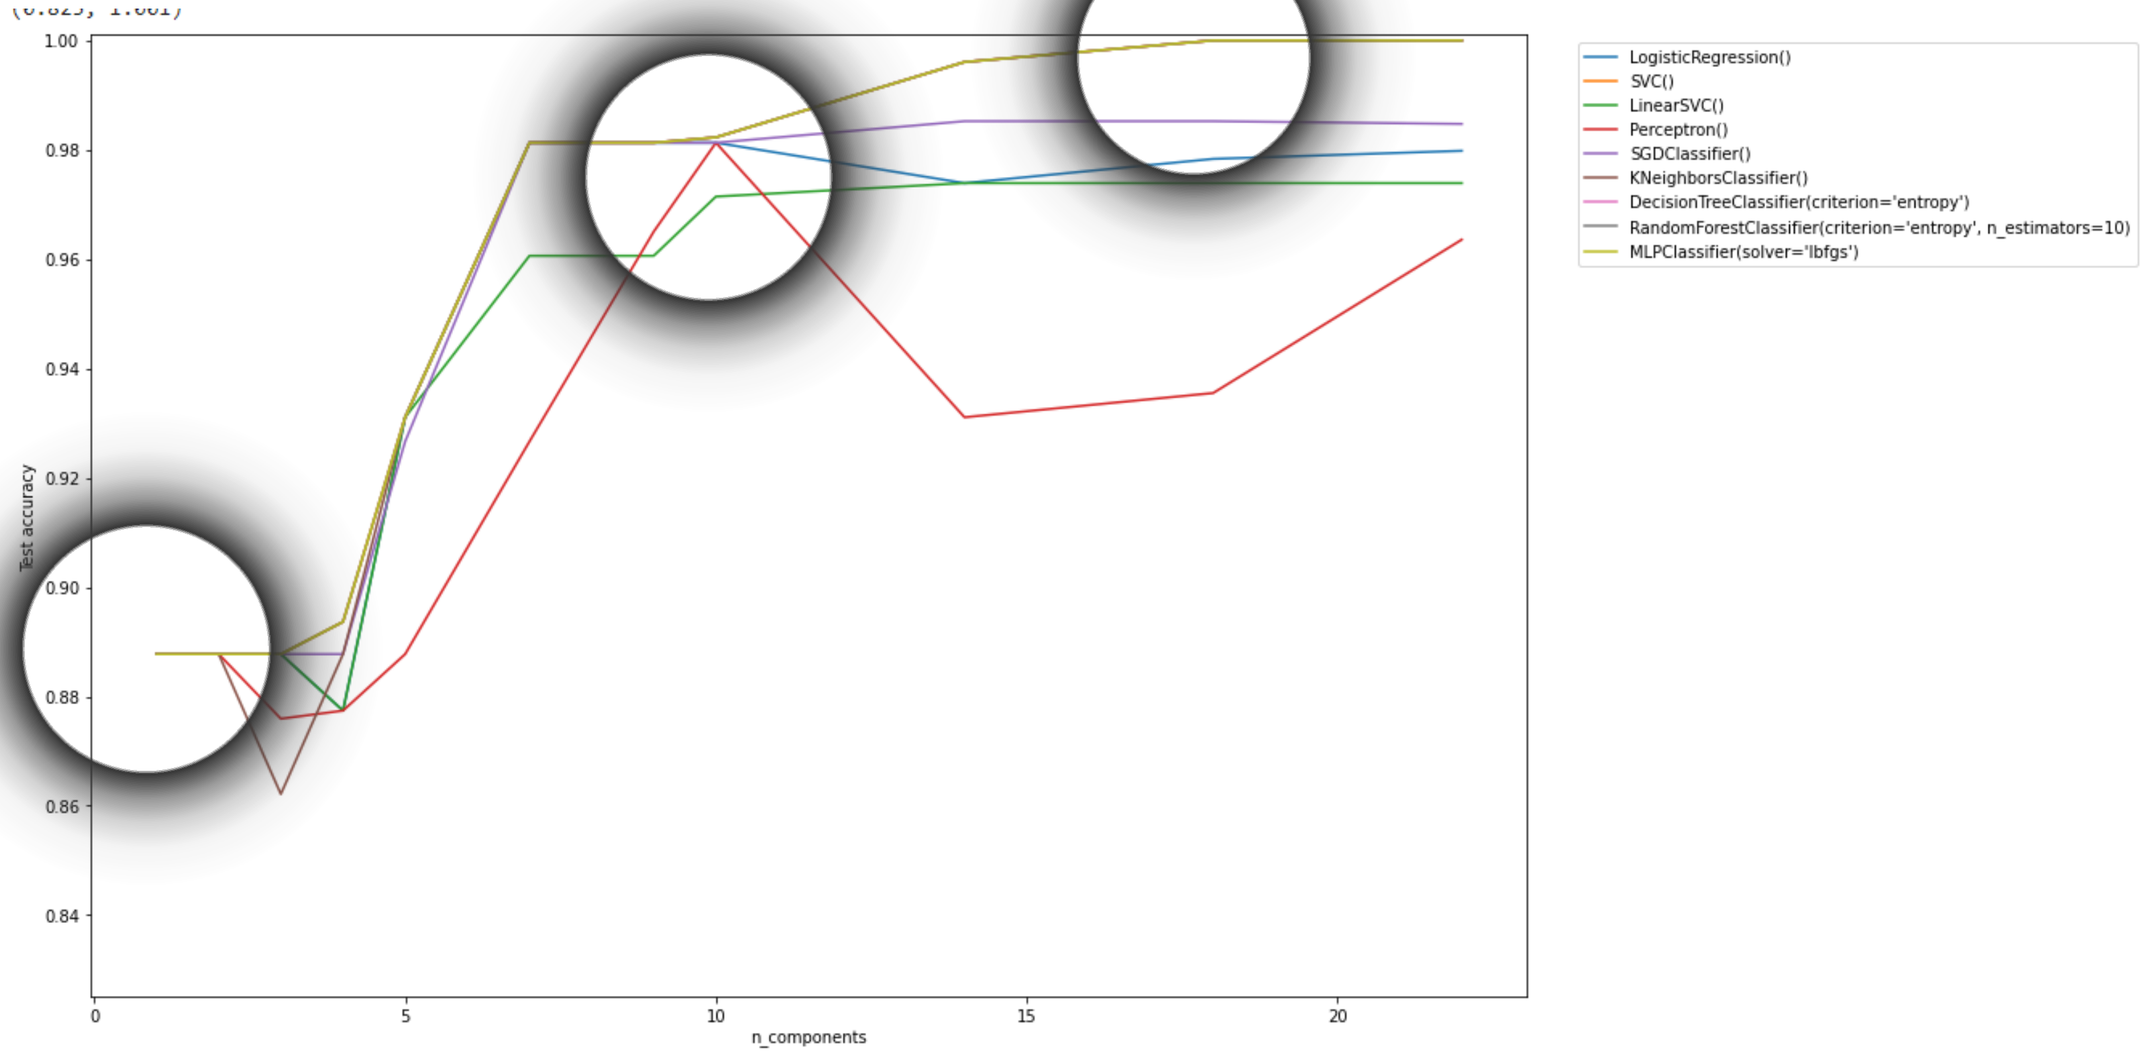

Millors atributs en solitari

Pel que fa la practica sembla el més interessant

Nom	Accuracy	Falsos Comestibles	Signe de la correlació
odor_n	0.88774	0.00410	1
odor_f	0.78877	0.07041	-1
stalk-surface-above-ring_k	0.78385	0.06663	-1
stalk-surface-below-ring_k	0.76809	0.07139	-1
ring-type_p	0.76711	0.03299	1
gill-size_b	0.75726	0.06910	1
gill-size_n	0.75726	0.06910	-1
bruises_f	0.75283	0.02527	-1
bruises_t	0.75283	0.02527	1
stalk-surface-above-ring_s	0.75234	0.06089	1

Millors atributs en solitari

L'atribut millor i amb menys falsos negatius és aquest:

`odor = none`

Els bolets que no fan olor, tels pots menjar sense preocupar-te massa

Resultats amb 6 atributs dels 116

ACCURACY

97.5%

Amb gairebé tots els models escollits

Necessito reduir el dataset

PCA per reduir el dataset

Mantenint un
90% de variança

31 atributs

ACCURACY

95% ~ 100%

Alguns models empitjoren lleugerament
Però la majoria segueix al 100%

2

PCA en dimensions 2 i 3

```
LogisticRegression          [0.86263 0.95618 0.95864]
SVC                         [0.94682 0.96898 0.96898]
LinearSVC                   [0.86312 0.9616  0.9611 ]
Perceptron                  [0.82669 0.95126 0.92171]
SGDClassifier               [0.8774  0.95372 0.95815]
KNeighborsClassifier        [1. 1. 1.]
DecisionTreeClassifier      [1. 1. 1.]
RandomForestClassifier      [1. 1. 1.]
MLPClassifier               [0.99015 1.      1.     ]
```

ACCURACY

100%

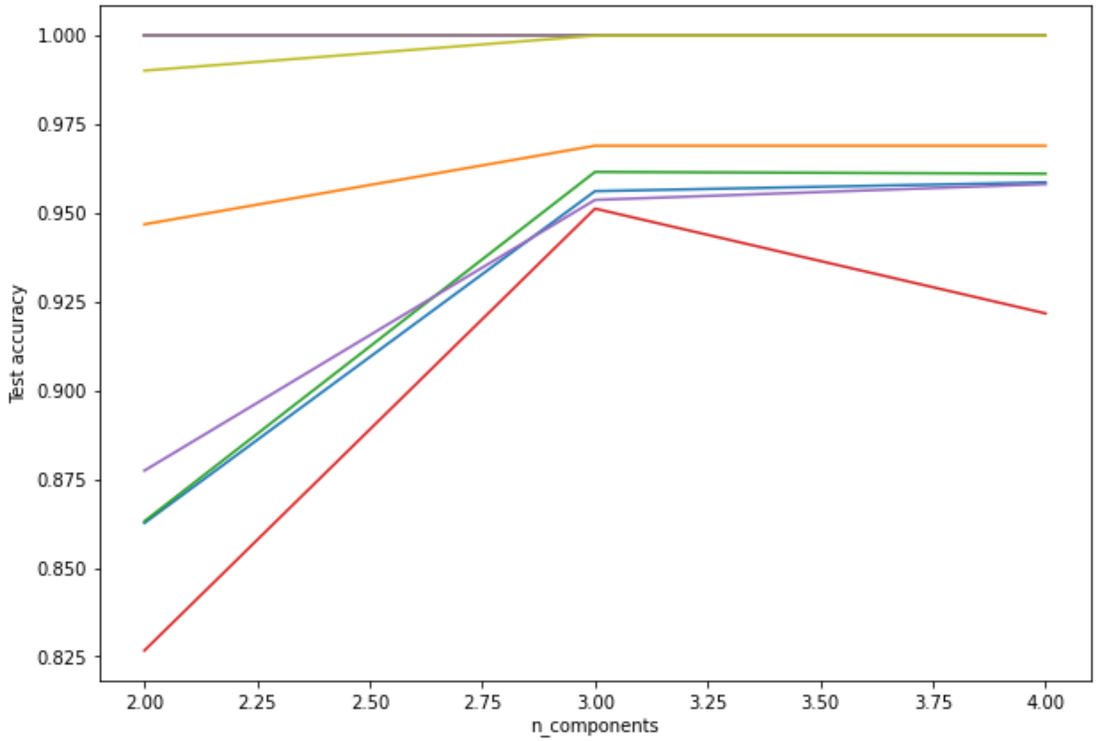

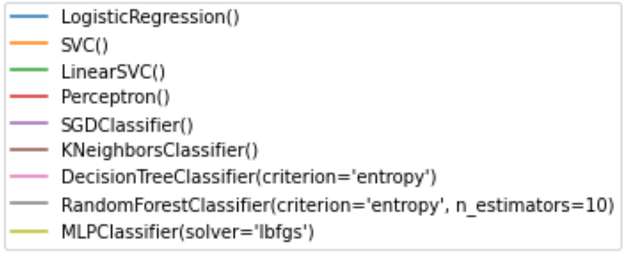

Com ho fa ?

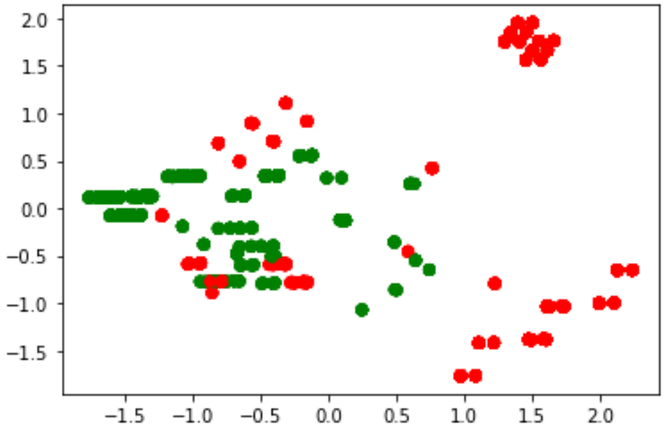

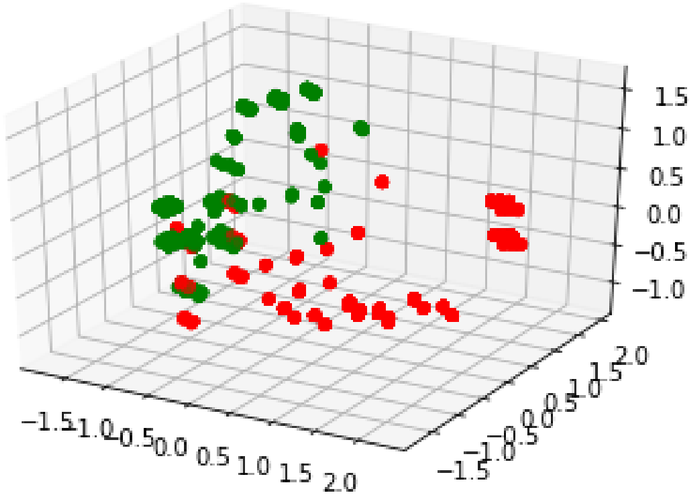

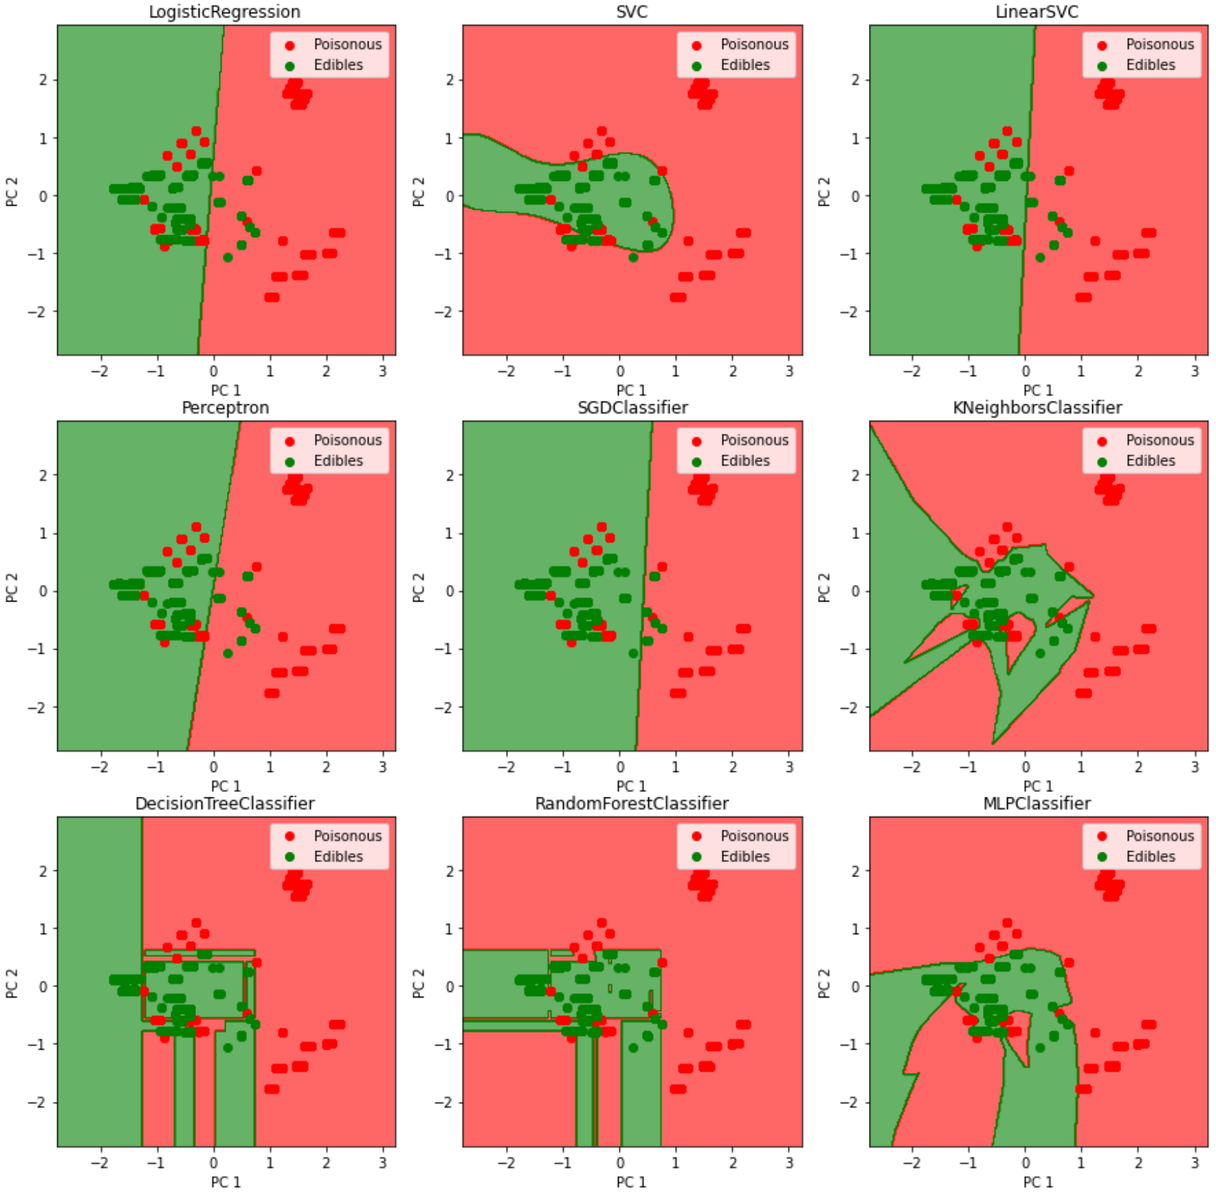
LogisticRegression
SVC
LinearSVC
Perceptron
SGDClassifier
KNeighborsClassifier
DecisionTreeClassifier
RandomForestClassifier
MLPClassifier
Poisonous
Edibles
PC 1
PC 2

t-SNE en dimensions 2 i 3

Alerta !

L'algoritme t-SNE transforma tot l'espai de cerca de manera no lineal i irreversible.

Així que no és d'aprenentatge supervisat. Es pot avaluar l'accuracy però serà molt sensible a noves mostres (s'hauria de repetir l'algoritme cada cop).

I és molt més lent

TSNE(n_components=2, n_iter=750, perplexity = 100)

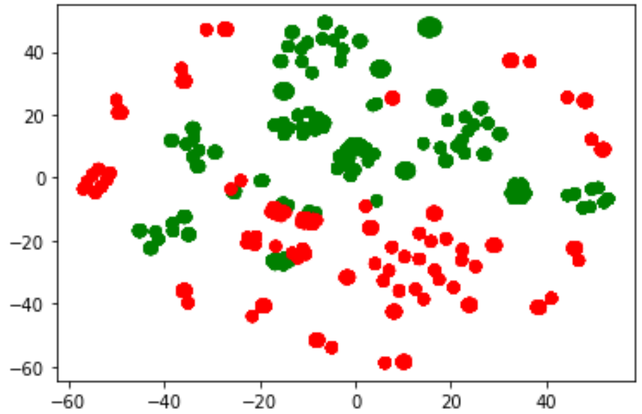

temps = 76 s

TSNE(n_components=3, n_iter=425, perplexity = 75)

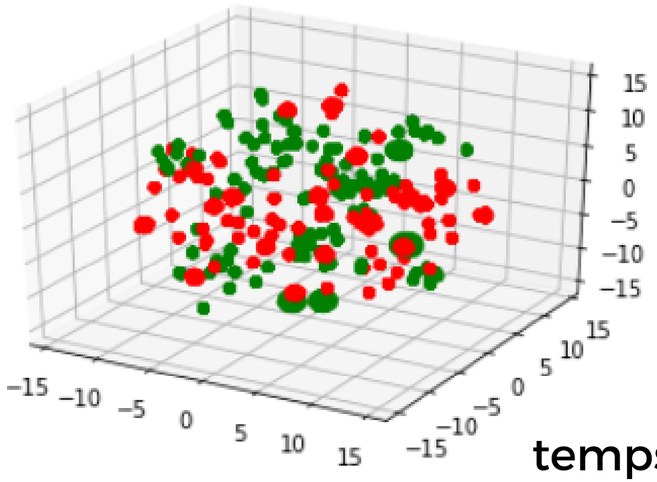

temps = 89 s

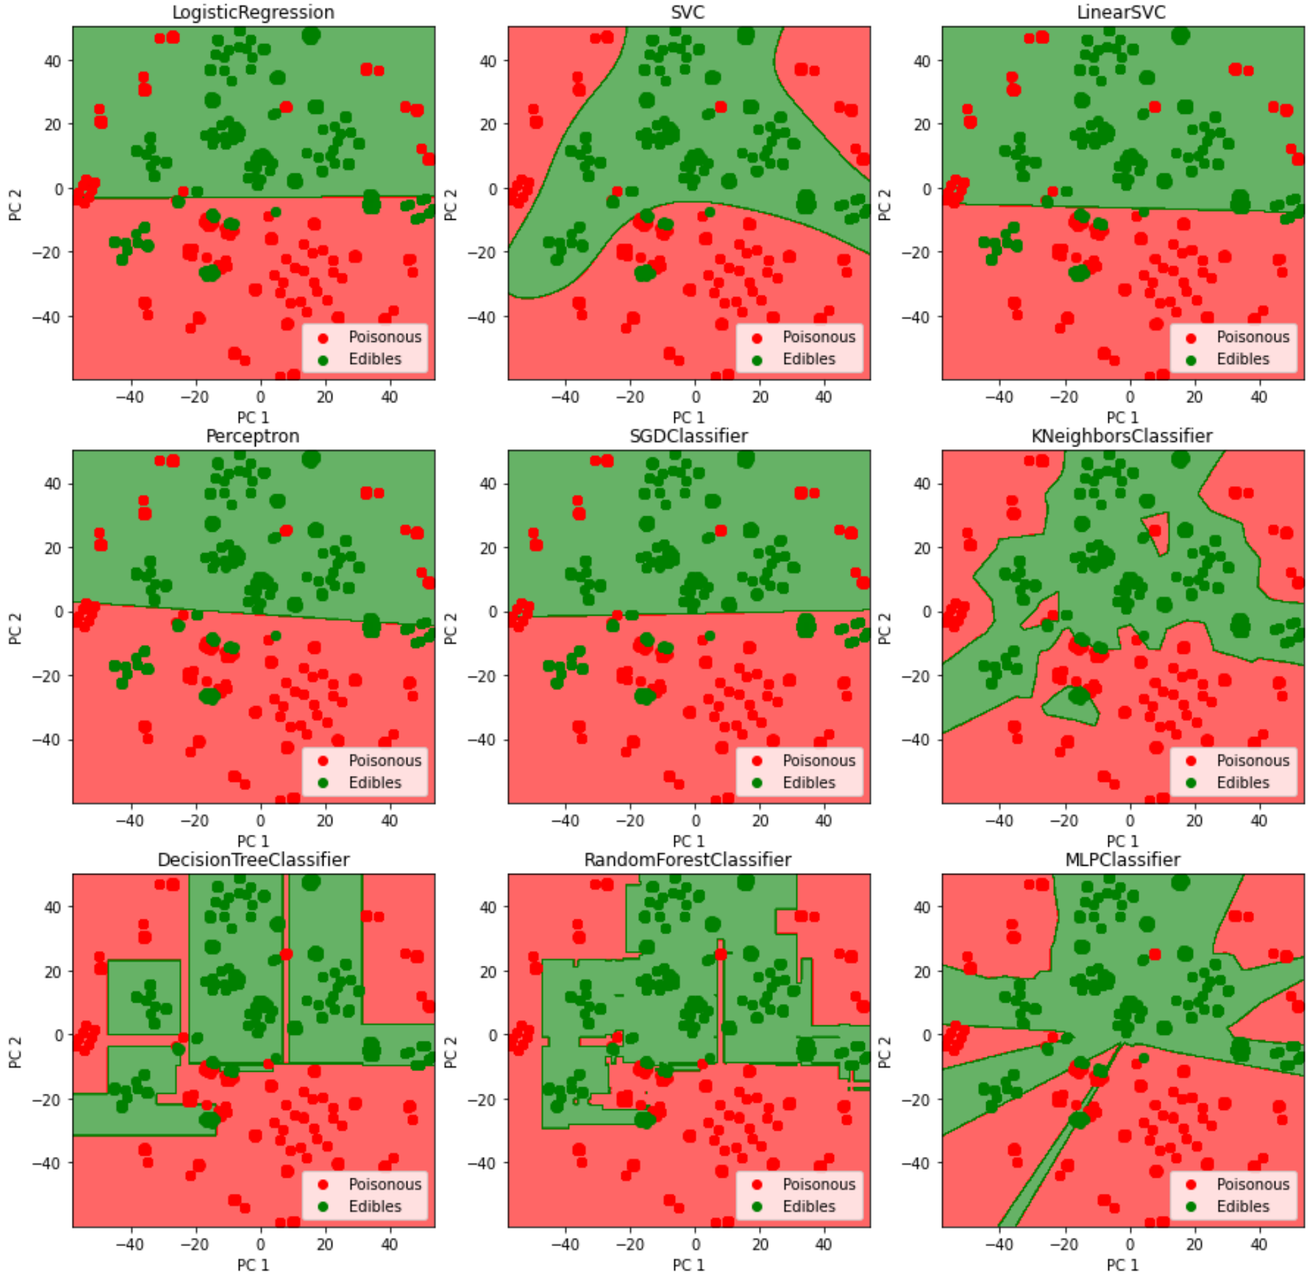

t-SNE mesurar accuracy

Separo al nou espai en X_train i X_test.

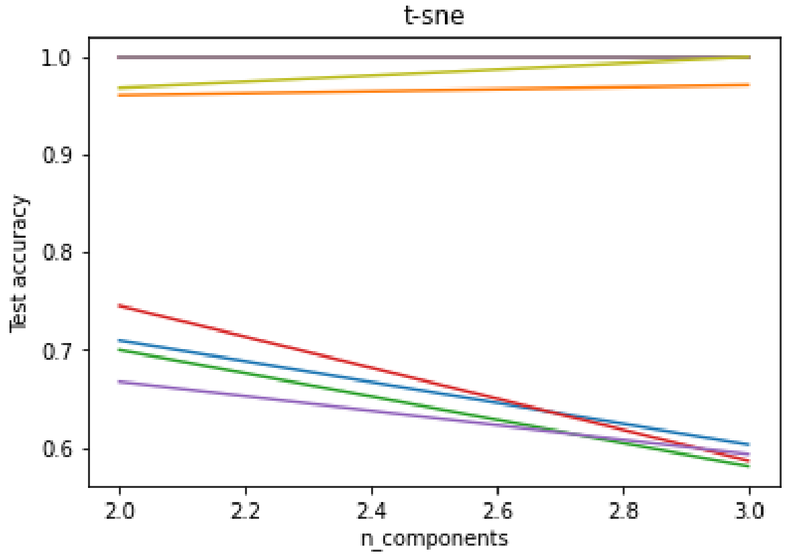

LogisticRegression()
SVC()
LinearSVC()
Perceptron()
SGDClassifier()
KNeighborsClassifier()
DecisionTreeClassifier(criterion='entropy')
RandomForestClassifier(criterion='entropy', n_estimators=10)
MLPClassifier(solver='lbfgs')

```
[[0.71    0.60336]
 [0.9611  0.97129]
 [0.70015 0.58121]
 [0.74545 0.58696]
 [0.66765 0.59352]
 [1.      1.     ]
 [1.      1.     ]
 [1.      1.     ]
 [0.96849 1.     ]]
```

ACCURACY

100%

EN ELS 4 MILLORS MODELS

PERO

per els models més senzills o lineals va pitjor

3

Conclusions

NO hi ha taula de resultats

La gran majoria eren 100%

Treballar amb un objectiu diferent

Visualització de les dades
Modificar l'espai de cerca
Importancia dels arguments
Graficar els models i transfromacions

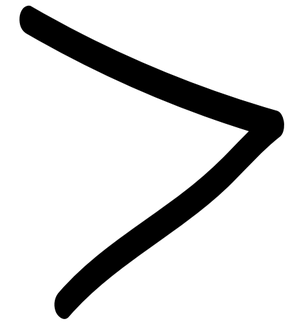

resultats